

1. ARSITEKTUR AGEN BERBASIS LANGGRAPH STATE MACHINE

DIRECTED ACYCLIC GRAPH (DAG) + SQLITE PERSISTENCE

1. Guard Node

Menganalisis intensi pengguna. Jika berada di luar lingkup karya ilmiah UM, dialihkan ke **Reject Node** dengan kalimat penolakan santun tanpa memicu retrieval LLM.

2. Thinking Node

Modul penalaran otonom via **LLM Structured Output (Pydantic)**. Memutuskan boolean `need_kb` dan `need_web` serta merumuskan kata kunci kueri penelusuran yang padat.

3. Tools Node

Mengeksekusi selektif: (a) **BM25 KB Retrieval** pada 134 halaman naskah Pedoman UM Press 2017, dan (b) **DuckDuckGo Web** untuk literatur/topik komplementer.

4. Generator Node

Menyintesis jawaban akademik grounded, menyertakan nomor Bab & Halaman buku pedoman resmi, serta menerapkan batasan 10 tahun kemutakhiran literatur ilmiah.

2. REKAYASA ENGINEERING TRADE-OFFS YANG DIAMBIL

Dimensi Trade-off	Pilihan Desain yang Diimplementasikan	Rasional & Dampak Operasional
State Machine DAG vs. ReAct Autonomous Loop	Arsitektur graf bersyarat deterministik (LangGraph) dengan transisi node yang terikat status <code>AcademicAgentState</code> .	Meniadakan risiko <i>infinite tool-calling loop</i> , konsumsi token terukur, serta menjamin latensi respon stabil (<0.8 detik <i>Time-to-First-Token</i>).
Structured Output (Pydantic) vs. Keyword/Regex	Penetapan keputusan pemanggilan tool berbasis skema <code>ToolDecision</code> terstruktur (boolean flags + kueri terfokus).	Model memahami konteks semantik kueri majemuk mahasiswa secara adaptif; sapaan santai dan terima kasih tidak memicu pemanggilan tool yang sia-sia.
BM25 / Keyword Indexing vs. Heavy Vector DB	Ekstraksi teks 134 halaman naskah nirkala dengan indexing berbasis kata kunci dan segmentasi bab/lampiran.	<i>Zero cold-start latency</i> , ukuran dependensi lokal ringan tanpa server database eksternal, dan 100% presisi sitasi nomor pasal/halaman tanpa <i>vector drift</i> .
Strict Academic Guardrail vs. General Open Chat	Penyaringan ketat di pintu gerbang utama untuk menolak kueri non-akademik (kuliner, bengkel, politik umum).	Fokus integritas sebagai agen resmi institusional Universitas Negeri Malang, melindungi dari <i>prompt injection</i> , dan menghemat kuota Gemini API.
SQLite Checkpointer vs. In-Memory Conversation	Penyimpanan riwayat obrolan multi-turn persisten ke basis data SQLite lokal (<code>storage/checkpoint.db</code>).	Memori percakapan mahasiswa tetap utuh antar-sesi atau saat browser di-refresh, tanpa overhead infrastruktur Redis/cloud database.

3. POTENSI TITIK KEGAGALAN & MEKANISME MITIGASI

Potensi Titik Kegagalan	Analisis Risiko & Dampak	Mekanisme Mitigasi yang Diterapkan
Halusinasi Aturan & Nomor Halaman	Model mengarang format margin atau nomor halaman fiktif yang menyesatkan mahasiswa.	Generator node mewajibkan sitasi eksplisit (Bab & Halaman) berdasarkan teks terambil dari 134 halaman pedoman resmi; dilarang berasumsi.
Rujukan Literatur Usang (>10 Tahun)	Model merekomendasikan literatur kadaluarsa karena LLM tidak memiliki konteks waktu riil.	Modul Time-Awareness Dinamis menyuntikkan tanggal aktif dan menghitung rentang 10 tahun kemutakhiran (2016–2026) pada prompt generator.
Injeksi Prompt / Topik Non-Akademik	Eksplorasi instruksi sistem atau pertanyaan yang merusak reputasi institusi.	Guard Node memvalidasi intensi di awal dan mengarahkan ke Reject Node dengan respon santun standar sivitas akademika UM.
Kegagalan Jaringan / Web Search Downtime	Pencarian DuckDuckGo terblokir atau putus koneksi saat kueri komplementer dieksekusi.	Mekanisme isolasi try-except terstruktur; jika web gagal, agen melanjutkan sintesis menggunakan basis pengetahuan pedoman internal.
Kegagalan Parsing JSON Model (Structured Output)	LLM menghasilkan teks bebas alih-alih JSON skema Pydantic saat trafik tinggi.	Fallback parser heuristik otomatis mengevaluasi teks respons dan memberikan default aman (<code>need_kb=True</code>) agar alur tidak terhenti.

Verifikasi Kualitas & Pengujian: 26/26 Unit Tests Passed (100% Lulus) mencakup guardrail, reasoning Pydantic, BM25 extraction, dan FastAPI SSE streaming.

Framework: LangGraph + Google Gemini + FastAPI