

1. ARSITEKTUR AGEN BERBASIS LANGGRAPH STATE MACHINE

DIRECTED ACYCLIC GRAPH (DAG) + SQLITE PERSISTENCE

 1. Guard Node Menganalisis intensi pengguna di gerbang awal. Jika berada di luar lingkup karya ilmiah UM, dialihkan ke Reject Node dengan kalimat penolakan santun tanpa memicu retrieval LLM.	 2. Thinking Node Penalaran otonom via LLM Structured Output (Pydantic). Memutuskan boolean <code>need_kb</code> dan <code>need_web</code> serta merumuskan kata kunci kueri penelusuran yang padat dan spesifik.	 3. Tools Node Mengeksekusi selektif: (a) BM25 KB Retrieval pada 134 halaman naskah Pedoman UM Press 2017, dan (b) DuckDuckGo Web untuk literatur/topik komplementer.	 4. Generator Node Menyintesis jawaban grounded dengan sitasi eksplisit Bab & Halaman buku pedoman resmi, serta menerapkan aturan otomatis batas 10 tahun kemutakhiran literatur ilmiah.
--	--	---	--

2. REKAYASA ENGINEERING TRADE-OFFS YANG DIAMBIL

Dimensi Trade-off	Pilihan Desain yang Diimplementasikan	Rasional & Dampak Operasional
State Machine DAG vs. ReAct Autonomous Loop	Arsitektur graf bersyarat deterministik (LangGraph) dengan transisi node yang terikat status <code>AcademicAgentState</code> .	Meniadakan risiko <i>infinite tool-calling loop</i> , konsumsi token terukur, serta menjamin latensi respon stabil (<0.8 detik <i>Time-to-First-Token</i>).
Structured Output (Pydantic) vs. Keyword/Regex	Penetapan keputusan pemanggilan tool berbasis skema <code>ToolDecision</code> terstruktur (boolean flags + kueri terfokus).	Model memahami konteks semantik kueri majemuk mahasiswa secara adaptif; sapaan santai dan terima kasih tidak memicu pemanggilan tool yang sia-sia.
BM25 / Keyword Indexing vs. Heavy Vector DB	Ekstraksi teks 134 halaman naskah nirkala dengan indexing berbasis kata kunci dan segmentasi bab/lampiran.	<i>Zero cold-start latency</i> , ukuran dependensi lokal ringan tanpa server database eksternal, dan 100% presisi sitasi nomor pasal/halaman tanpa <i>vector drift</i> .
Strict Academic Guardrail vs. General Open Chat	Penyaringan ketat di pintu gerbang utama untuk menolak kueri non-akademik (kuliner, bengkel, politik umum).	Fokus integritas sebagai agen resmi institusional Universitas Negeri Malang, melindungi dari <i>prompt injection</i> , dan menghemat kuota Gemini API.
SQLite Checkpointer vs. In-Memory Conversation	Penyimpanan riwayat obrolan multi-turn persisten ke basis data SQLite lokal (<code>storage/checkpoint.db</code>).	Memori percakapan mahasiswa tetap utuh antar-sesi atau saat browser di-refresh, tanpa overhead infrastruktur Redis/cloud database.

3. POTENSI TITIK KEGAGALAN & MEKANISME MITIGASI

Potensi Titik Kegagalan	Analisis Risiko & Dampak	Mekanisme Mitigasi yang Diterapkan
Halusinasi Aturan & Nomor Halaman	Model mengarang format margin atau nomor halaman fiktif yang menyesatkan mahasiswa.	Generator node mewajibkan sitasi eksplisit (Bab & Halaman) berdasarkan teks terambil dari 134 halaman pedoman resmi; dilarang berasumsi.
Rujukan Literatur Usang (> 10 Tahun)	Model merekomendasikan literatur kadaluarsa karena LLM tidak memiliki konteks waktu riil.	Modul Time-Awareness Dinamis menyuntikkan tanggal aktif dan menghitung rentang 10 tahun kemutakhiran (2016–2026) pada prompt generator.
Injeksi Prompt / Topik Non-Akademik	Eksplorasi instruksi sistem atau pertanyaan yang merusak reputasi institusi.	Guard Node memvalidasi intensi di awal dan mengarahkan ke Reject Node dengan respon santun standar sivitas akademika UM.
Kegagalan Jaringan / Web Search Downtime	Pencarian DuckDuckGo terblokir atau putus koneksi saat kueri komplementer dieksekusi.	Mekanisme isolasi try-except terstruktur; jika web gagal, agen melanjutkan sintesis menggunakan basis pengetahuan pedoman internal.
Kegagalan Parsing JSON Model (Structured Output)	LLM menghasilkan teks bebas alih-alih JSON skema Pydantic saat trafik tinggi.	Fallback parser heuristik otomatis mengevaluasi teks respons dan memberikan default aman (<code>need_kb=True</code>) agar alur tidak terhenti.

Verifikasi Kualitas & Pengujian: 26/26 Unit Tests Passed (100% Lulus) mencakup guardrail, reasoning Pydantic, BM25 extraction, dan FastAPI SSE streaming.

Framework: LangGraph + Google Gemini + FastAPI